

José Manuel Ortega Candel / jmoc25@gmail.com

NLP Language Recognition

Documento técnico del pipeline supervisado de Machine Learning para clasificación automática de idioma mediante n-gramas de caracteres

DATASET	MODELOS	IDIOMAS	ALGORITMO
594 textos	7 clasificadores	EN ES FR DE IT PT	TF-IDF + sklearn

Abstract

Este documento describe el pipeline completo de Machine Learning supervisado para la detección automática del idioma en textos de longitud arbitraria. La solución se basa en la vectorización TF-IDF de n-gramas de caracteres y evalúa siete clasificadores. El uso de algoritmos como regresión logística, random forest, naive bayes, gradient boost y multilayer perceptron consiguen alcanzar valores altos de accuracy sobre el conjunto de test, demostrando que las características morfológicas de nivel de carácter son suficientes para distinguir lenguas románicas y germánicas con alta precisión.

Introducción

La identificación automática del idioma de un texto es un problema fundamental en el procesamiento del lenguaje natural (PLN). Tiene aplicaciones directas en sistemas de traducción automática, motores de búsqueda multilingüe, moderación de contenido y análisis de redes sociales.

A pesar de la existencia de herramientas pre entrenadas como langdetect o fastText, el presente proyecto se plantea el reto técnico de construir un sistema de clasificación de idioma, prescindiendo de librerías de alto nivel especializadas. Esta decisión responde a la necesidad de comprender y controlar el ciclo de vida completo del dato: desde la ingeniería de características hasta la inferencia del modelo.

El objetivo es implementar un pipeline completo utilizando aprendizaje supervisado que extrae características estadísticas del texto mediante n-gramas de caracteres con ponderación TF-IDF y entrena clasificadores estándar utilizando el framework de python scikit-learn <https://scikit-learn.org/stable>. La elección de n-gramas de caracteres frente a n-gramas de palabras está motivada por su robustez ante textos cortos y porque los patrones morfológicos a nivel de carácter son altamente discriminativos entre familias lingüísticas.

El uso de la ponderación TF-IDF (Term Frequency - Inverse Document Frequency) permite transformar estas secuencias de caracteres en vectores numéricos, resaltando aquellos patrones morfológicos que son únicos de cada familia lingüística. Por ejemplo, la presencia de ciertas combinaciones de caracteres permite al modelo diferenciar con alta precisión entre idiomas estrechamente relacionados (como el español y el portugués) o identificar idiomas con sistemas de escritura compartidos, pero con gramáticas divergentes.

Formulación del problema

El objetivo principal de este trabajo es desarrollar, entrenar y validar un modelo de aprendizaje automático capaz de reconocer múltiples idiomas con alta precisión. A través de este proceso, se explorará la selección de hiper parámetros, la evaluación del rendimiento mediante métricas de clasificación multiclase y la capacidad de generalización del sistema ante diversos dominios textuales, consolidando así una solución robusta y personalizada para el reconocimiento del lenguaje.

Campo	Descripción
Tipo de aprendizaje	Supervisado
Tarea	Clasificación multiclase (6 clases)
Input	Texto en bruto (longitud variable)
Output	Código de idioma: en es fr de it pt
Métrica principal	Accuracy + F1-score

Justificación de la métrica

Se utiliza **F1-score** como métrica de optimización porque el dataset está perfectamente balanceado (99 muestras por clase). El **Accuracy** se usa como métrica de reporte: un 96 % implica fallar en 4 textos de cada 100.

Recopilación de datos

Origen del dataset


El dataset se ha construido específicamente para este proyecto. Se generaron 99 frases temáticas por idioma cubriendo dominios variados: ciencia, tecnología, historia, cultura, ecología, economía y vida cotidiana.

Característica	Valor
Total de registros	594 frases
Idiomas	6 (99 frases por idioma)
Balance de clases	Perfectamente balanceado (16.67% por clase)
Longitud media	~68 caracteres / ~11 palabras por frase
Columnas	text (str), language (str — código ISO 639-1)
Fuente	Dataset generado ad hoc

Text	Code	Language	Words
O rio flui suavemente pelo verde vale entre as montanhas	pt	Portuguese	10
La investigación genética ofrece nuevas esperanzas para enfermedades	es	Spanish	8
La frutta e la verdura fresche sono essenziali per la salute	it	Italian	11
Engineers designed a revolutionary new transportation system	en	English	7
La fusione ha creato la più grande azienda dell'industria globale mondiale	it	Italian	12
The hospital introduced new treatment procedures	en	English	6
Leer libros mejora el vocabulario y la imaginación	es	Spanish	8
Os resultados eleitorais surpreenderam muitos analistas políticos experientes	pt	Portuguese	8
Fotografie hält Momente fest die sonst verloren gehen würden für immer	de	German	11
The election results surprised many political analysts	en	English	7

Distribución por idioma

Idioma	Muestras	Porcentaje	Familia
English (en)	99	16.67%	Germanic
Spanish (es)	99	16.67%	Romance
French (fr)	99	16.67%	Romance
German (de)	99	16.67%	Germanic
Italian (it)	99	16.67%	Romance
Portuguese (pt)	99	16.67%	Romance




Evaluación de los datos

Exploración inicial

El análisis exploratorio revela que el dataset no presenta valores nulos ni duplicados. La distribución de clases es perfectamente uniforme, lo que elimina la necesidad de técnicas de balanceo como sobremuestreo o submuestreo.


Estadística	Valor
Longitud media (chars)	~68
Longitud máxima (chars)	~150
Longitud mínima (chars)	~35
Palabras por texto (media)	~11
Valores nulos	0
Duplicados exactos	0



N-gramas más característicos por idioma

El análisis TF-IDF identifica los patrones de caracteres más exclusivos de cada idioma:

Idioma	N-gramas más característicos
German (de)	sch, ge, die, ei, er, en
English (en)	th, the, he, ed
Spanish (es)	el, es, la, os, del, ón
French (fr)	eau, eux, les, le, iqu
Italian (it)	il, di, to, zio
Portuguese (pt)	ao, os, as



Ingeniería de características

Preprocesamiento

El preprocesamiento aplicadores el siguiente:

- Conversión a minúsculas del texto.
- Limpiar espacios múltiples a un único espacio.
- strip_accents=None — los acentos se conservan porque son discriminatorios.
- Sin stemming ni lematización — los n-gramas de caracteres no lo requieren.

Vectorización: TF-IDF de n-gramas de caracteres

La ingeniería de características principal realizada es la vectorización TF-IDF con la clase de sklearn **TfidfVectorizer(analyzer='char_wb')**. El modo char_wb envuelve cada palabra en espacios antes de extraer n-gramas, capturando los límites de palabra como información adicional.



Parámetro	Valor	Justificación
analyzer	char_wb	N-gramas con límites de palabra
ngram_range	(2, 4)	Bi-, tri- y tetra grams
max_features	50.000	50k features de mayor TF-IDF
sublinear_tf	True	log(1+TF) para comprimir frecuencias altas
strip_accents	None	Conservar acentos

Partition train/test

Para las pruebas se realiza una partición **de 80% para data de entrenamiento y 20% para pruebas** con semilla aleatoria fija (random_state=42). La estratificación garantiza que cada idioma esté representado de forma proporcional.

% Entrenamiento / Pruebas

% conjunto de pruebas



Parámetro	Valor
Total muestras	594
Train (80%)	475 muestras (~79-80 por idioma)
Test (20%)	119 muestras (~20 por idioma)
Estratificado	Si — mantiene distribución de clases
random_state	42 — reproducibilidad garantizada

Entrenamiento del modelo

Arquitectura del Pipeline

Todos los modelos se encapsulan en un **sklearn.Pipeline** que encadena el vectorizador TF-IDF con el clasificador. Esto garantiza que la transformación de features no presente fuga de datos.

```
Pipeline: TfidfVectorizer(char_wb, 2-4 grams) → [to_dense*] → Classifier
```

(*) MLP y XGBoost requieren matrices densas.

Modelos evaluados

Modelo	Descripción	Calidad	Velocidad
Logistic Regression	Regularización L2, solver lbfgs	Muy alta	Muy rápido
Linear SVC	SVM lineal, margen de separación	Muy alta	Rápido
Naive Bayes	Probabilidad condicional (Laplace)	Alta	Muy rápido
Random Forest	Ensemble de 100 árboles	Alta	Moderado
Gradient Boosting	Boosting secuencial, lr=0.1	Alta	Lento
MLP Classifier	Red neuronal, 1 capa (128 nodos)	Alta	Moderado
XGBoost	Boosting optimizado + regulariz.	Alta	Moderado


Logistic Regression

La Regresión Logística es un algoritmo de aprendizaje supervisado utilizado principalmente para problemas de clasificación binaria, donde el objetivo es predecir la probabilidad de que una instancia pertenezca a una categoría específica (como 0 o 1, "Sí" o "No"). Este algoritmo destaca por ser altamente interpretable y menos propenso al sobreajuste en conjuntos de datos con relaciones lineales claras entre las características y las etiquetas de clase.

Métricas del modelo Logistic Regression

Test Accuracy	0.9748
F1-score	0.9750
Precisión	0.9769
Recall	0.9750
Muestras test	119
Errores en test	3 / 119 (2.52%)

Matriz de confusión



Resultados por idioma

Idioma	Precisión	Recall	F1	Soporte
German (de)	1.00	1.00	1.00	19
English (en)	1.00	0.95	0.97	20
Spanish (es)	0.95	1.00	0.98	20
French (fr)	0.95	1.00	0.98	20
Italian (it)	0.95	1.00	0.98	20
Portuguese (pt)	1.00	0.90	0.95	20

Análisis de errores

El modelo comete únicamente **3 errores** sobre 119 muestras de test. Los errores se concentran en el par **portugues y español**, que comparten numerosos n-gramas por su proximidad lingüística. El alemán es el idioma mejor clasificado con valores perfectos de precisión y recall.

Muestras clasificadas de forma errónea

Texto	Etiqueta real	Predicción
a biblioteca guarda milhares de manuscritos históricos raros e valiosos...	Portuguese	Spanish
ela caminhava lentamente pela floresta de outono serena e tranquila...	Portuguese	Spanish
street art transforms urban spaces into open air galleries...	English	French

Linear SVC

El modelo Linear SVC (Linear Support Vector Classification) es una implementación del algoritmo de Máquinas de Vectores de Soporte (SVM) optimizada para problemas de clasificación lineal con grandes volúmenes de datos. A continuación, se describen sus características fundamentales:

- Búsqueda del hiperplano óptimo: Su objetivo es encontrar un hiperplano en un espacio multidimensional que separe las clases con el margen más amplio posible.
- Maximización del margen: A diferencia de otros algoritmos, el Linear SVC intenta maximizar la distancia entre el hiperplano de decisión y los puntos más cercanos de cada clase, conocidos como vectores de soporte.
- Eficiencia en alta dimensionalidad: Es especialmente eficaz cuando el número de características es mayor que el número de muestras, lo que lo hace ideal para el análisis de texto con TF-IDF donde el vocabulario de n-gramas genera vectores muy extensos.
- Versatilidad y regularización: Utiliza parámetros de penalización para gestionar el compromiso entre el error de clasificación y la simplicidad del modelo, permitiendo una gran robustez frente al sobreajuste.
- Enfoque lineal: Al utilizar un kernel lineal, es computacionalmente mucho más rápido que las versiones de SVM con kernels no lineales, facilitando el entrenamiento en pipelines de scikit-learn con conjuntos de datos masivos.

Métricas del modelo Linear SVC

Test Accuracy	0.9748
F1-score	0.9748
Precisión	0.9762
Recall	0.9750
Muestras test	119
Errores en test	3 / 119 (2.52%)

Naive Bayes

El modelo Naive Bayes es un clasificador probabilístico basado en el Teorema de Bayes, ampliamente utilizado en el Procesamiento del Lenguaje Natural debido a su simplicidad y eficacia en la clasificación de textos. A continuación, se describen sus características fundamentales:

- **Asunción de independencia:** Su nombre "Naive" (ingenuo) proviene de la premisa de que todas las características de entrada (en este caso, los n-gramas) son independientes entre sí dada la clase, lo que simplifica enormemente el cálculo computacional.
- **Basado en probabilidad condicional:** El algoritmo calcula la probabilidad de que un texto pertenezca a un idioma basándose en la frecuencia de aparición de patrones específicos observados durante el entrenamiento.
- **Alta eficiencia:** Requiere una cantidad relativamente pequeña de datos de entrenamiento para estimar los parámetros necesarios y es extremadamente rápido tanto en la fase de entrenamiento como en la de predicción.
- **Eficacia con características irrelevantes:** Es sorprendentemente robusto y tiende a funcionar bien incluso cuando la asunción de independencia no se cumple perfectamente, siendo un estándar para tareas de detección de idioma y filtrado de spam.
- **Integración con TF-IDF:** Funciona de manera óptima con representaciones vectoriales de texto, manejando con éxito la alta dimensionalidad producida por la extracción de n-gramas de caracteres.

Métricas del modelo Naive Bayes

Test Accuracy	0.9748
F1-score	0.9748
Precisión	0.9762
Recall	0.9750
Muestras test	119
Errores en test	3 / 119 (2.52%)

Random Forest


El modelo Random Forest es un algoritmo de aprendizaje supervisado de tipo ensemble que combina múltiples árboles de decisión para generar una predicción más robusta y precisa. A continuación, se describen sus principios fundamentales:

- **Ensamble de árboles (Bagging):** Funciona mediante la creación de una "bosque" de árboles de decisión entrenados de forma independiente sobre diferentes subconjuntos aleatorios de los datos.
- **Votación mayoritaria:** Para la clasificación de idiomas, cada árbol emite un "voto" por una categoría y el modelo final selecciona la clase que haya sido predicha por la mayoría de los árboles, lo que reduce drásticamente el error de predicción.
- **Reducción del sobreajuste:** Al promediar los resultados de múltiples árboles, el modelo compensa la tendencia de los árboles de decisión individuales a memorizar el ruido de los datos (overfitting), mejorando la generalización ante nuevos textos.
- **Importancia de las características:** Permite identificar qué n-gramas de caracteres son más determinantes para diferenciar un idioma de otro, ofreciendo una alta capacidad de interpretación sobre el peso de cada patrón morfológico.
- **No linealidad:** A diferencia de la Regresión Logística o el Linear SVC, Random Forest es capaz de capturar relaciones complejas y no lineales entre las características del texto sin necesidad de transformar los datos.

Métricas del modelo Random Forest

Test Accuracy	0.9748
F1-score	0.9746
Precisión	0.9758
Recall	0.9750
Muestras test	119
Errores en test	3 / 119 (2.52%)

Matriz de confusión



Resultados por idioma

Idioma	Precisión	Recall	F1	Soporte
German (de)	0.95	1.00	0.97	19
English (en)	1.00	0.90	0.95	20
Spanish (es)	0.95	1.00	0.98	20
French (fr)	0.95	1.00	0.98	20
Italian (it)	1.00	1.00	1.00	20
Portuguese (pt)	1.00	0.95	0.97	20

Análisis de errores

El modelo comete únicamente **3 errores** sobre 119 muestras de test. Los errores corresponden a los pares **ingles-frances**, **portugues-español**, **inglés-alemán**. El italiano es el idioma mejor clasificado con valores perfectos de precisión y recall.

MLP Classifier


MLP Classifier (Multi-layer Perceptron) es un modelo de aprendizaje supervisado basado en redes neuronales artificiales de tipo feedforward, diseñado para abordar problemas de clasificación complejos mediante el aprendizaje de funciones no lineales. A continuación, se describen sus componentes clave:

- **Arquitectura de capas:** Se compone de una capa de entrada (donde recibe los vectores TF-IDF), una o más capas ocultas con neuronas interconectadas y una capa de salida que predice el idioma correspondiente.
- **Aprendizaje mediante backpropagation:** El modelo ajusta los pesos de las conexiones entre neuronas de forma iterativa, minimizando el error entre la predicción y el idioma real a través del algoritmo de propagación hacia atrás.
- **Funciones de activación no lineales:** Utiliza funciones como ReLU o Sigmoide en sus capas ocultas, lo que le permite capturar patrones y dependencias complejas en los n-gramas de caracteres que otros modelos lineales podrían pasar por alto.
- **Alta capacidad de representación:** Es capaz de modelar fronteras de decisión extremadamente complejas, siendo útil cuando la distinción entre idiomas o familias lingüísticas requiere analizar combinaciones sutiles de características.
- **Sensibilidad a la configuración:** A diferencia de modelos más sencillos, requiere una sintonización cuidadosa de hiper parámetros (como la tasa de aprendizaje y el número de neuronas) para evitar el sobreajuste y garantizar una convergencia óptima dentro del framework scikit-learn.

Métricas del modelo MLP Classifier

Test Accuracy	0.9580
F1-score	0.9581
Precisión	0.9583
Recall	0.9583
Muestras test	119
Errores en test	5 / 119 (2.52%)

Matriz de confusión



Resultados por idioma

Idioma	Precisión	Recall	F1	Soporte
German (de)	1.00	1.00	1.00	19
English (en)	0.95	0.95	0.95	20
Spanish (es)	0.95	0.95	0.95	20
French (fr)	0.95	0.95	0.95	20
Italian (it)	0.95	1.00	0.98	20
Portuguese (pt)	0.95	0.90	0.92	20

Análisis de errores

El modelo comete únicamente **5 errores** sobre 119 muestras de test. Los errores corresponden a los pares **ingles-frances**, **portugues-español**, **portugues-italiano**. El alemán es el idioma mejor clasificado con valores perfectos de precisión y recall.

Gradient Boosting


El modelo Gradient Boosting es un algoritmo de aprendizaje supervisado de tipo ensemble que construye un modelo predictivo fuerte mediante la combinación secuencial de múltiples modelos débiles (típicamente árboles de decisión cortos). A continuación, se describen sus principios fundamentales:

- Construcción secuencial e iterativa: A diferencia de Random Forest, donde los árboles se crean en paralelo, en Gradient Boosting los árboles se construyen uno tras otro.
- Corrección de errores: Cada nuevo árbol se entrena específicamente para predecir y corregir los errores residuales (la diferencia entre el valor real y la predicción) cometidos por los árboles anteriores.
- Optimización de función de pérdida: Utiliza algoritmos de optimización basados en gradiente para minimizar el error global del sistema en cada paso, lo que resulta en una precisión muy alta.
- Alta potencia predictiva: Es considerado uno de los algoritmos más potentes para datos estructurados y representaciones vectoriales como TF-IDF, logrando a menudo resultados superiores en tareas de clasificación multiclase.
- Control de complejidad: Requiere un ajuste cuidadoso de parámetros como la tasa de aprendizaje (learning rate) y el número de estimadores para evitar que el modelo se vuelva demasiado complejo y caiga en el sobreajuste.

Métricas del modelo Gradient Boosting

Test Accuracy	0.9580
F1-score	0.9584
Precisión	0.9616
Recall	0.9583
Muestras test	119
Errores en test	5 / 119 (2.52%)

Matriz de confusión



Resultados por idioma

Idioma	Precisión	Recall	F1	Soporte
German (de)	1.00	1.00	0.97	19
English (en)	1.00	0.90	0.95	20
Spanish (es)	0.87	1.00	0.93	20
French (fr)	0.95	0.95	0.95	20
Italian (it)	1.00	0.95	0.97	20
Portuguese (pt)	1.00	0.95	0.97	20

Análisis de errores

El modelo comete únicamente **5 errores** sobre 119 muestras de test. Los errores corresponden a los pares **ingles-frances**, **portugues-español**, **italiano-español**, **inglés-alemán**, **francés-español**.

XGBoost


XGBoost (Extreme Gradient Boosting) es una implementación avanzada y altamente optimizada del algoritmo de Gradient Boosting, diseñada específicamente para maximizar la velocidad de cómputo y el rendimiento del modelo en tareas de clasificación y regresión compleja. A continuación, se describen sus características diferenciales:

- **Optimización del sistema:** A diferencia del Gradient Boosting tradicional, XGBoost utiliza computación en paralelo y algoritmos de búsqueda de divisiones más eficientes, lo que acelera drásticamente el entrenamiento con grandes volúmenes de datos.
- **Regularización integrada:** Incluye penalizaciones L1 (Lasso) y L2 (Ridge) en su función objetiva, lo que ayuda a controlar la complejidad del modelo y previene el sobreajuste de manera más efectiva que las versiones estándar.
- **Manejo de valores faltantes:** Posee una capacidad innata para aprender de forma automática cómo tratar datos faltantes o nulos, asignándoles una dirección predeterminada en los nodos de decisión.
- **Poda de árboles profunda:** Utiliza un enfoque de "poda hacia atrás" (pruning) basado en un parámetro de ganancia mínima, lo que evita que el modelo cree ramas que no aportan un valor predictivo real.
- **Ideal para alta dimensionalidad:** Su eficiencia lo convierte en una opción de alto rendimiento para trabajar con matrices dispersas, como las resultantes de aplicar TF-IDF sobre n-gramas de caracteres en el reconocimiento de idiomas.

Métricas del modelo XGBoost

Test Accuracy	0.9580
F1-score	0.9577
Precisión	0.9595
Recall	0.9583
Muestras test	119
Errores en test	5 / 119 (2.52%)

Matriz de confusión



Resultados por idioma



Idioma	Precisión	Recall	F1	Soporte
German (de)	0.95	1.00	0.95	19
English (en)	0.95	0.90	0.92	20
Spanish (es)	0.95	1.00	0.98	20
French (fr)	1.00	0.90	0.95	20
Italian (it)	0.95	1.00	0.98	20
Portuguese (pt)	1.00	0.95	0.97	20

Análisis de errores

El modelo comete únicamente **5 errores** sobre 119 muestras de test. Los errores corresponden a los pares **ingles-alemán, portugues-italiano, francés-inglés, inglés-alemán, francés-español**.

Comparativa de todos los modelos

Modelo	Accuracy	Macro F1	Train Time	Nota
Logistic Regression	0.9748	0.9750	<0.1s	Mejor modelo
Linear SVC	0.9748	0.9748	~0.4s	
Naive Bayes	0.9748	0.9748	~0.01s	Más rápido
Random Forest	0.9748	0.9746	~35s	
MLP Classifier	0.9580	0.9581	~17s	
XGBoost	0.9580	0.9577	~9s	
Gradient Boosting	0.9580	0.9584	~30s	



Ajuste de hiperparametros

Se puede aplicar **GridSearchCV** con 5-fold cross-validation sobre el conjunto de entrenamiento. La métrica de optimización es la Accuracy promedio de los 5 folds. GridSearchCV prueba todas las combinaciones posibles y selecciona la de mayor CV score.

Modelo a ajustar:

Logistic Regression

CV folds (K)

5



Modelo seleccionado: Logistic Regression

Ajusta los rangos de cada hiperparámetro. El grid search probará **todas las combinaciones posibles** de los valores configurados.

C

Min

0,1000

- +

Max

10,0000

- +

Nº valores

3

- +

→ Se explorarán: [0.1, 5.05, 10.0]



Inverso de la regularización — valores altos = menos regularización

Grid de búsqueda en Logistic Regression

Parámetro	Valores explorados	Descripción
clf__C	[0.1, 1.0, 10.0]	Inverso de la regularización L2
clf__solver	[lbfgs, liblinear]	Algoritmo de optimización

Comparativa baseline vs modelo afinado

Métrica	Baseline	Tuned	Mejora
CV Accuracy (5-fold)	0.9832	0.9895	+0.63%
Test Accuracy	0.9748	0.9748	+0.00%
Macro F1	0.9750	0.9750	+0.00%
Mejores parámetros	C=1, lbfgs	C=10, lbfgs	—

Interpretación: El ajuste de hiperparametros consigue mejorar el CV score en **+0.63%** (de 0.9832 a 0.9895), indicando mejor generalización. El test accuracy se mantuvo estable porque el baseline ya estaba bien ajustado. C=10 implica menor regularización, permitiendo capturar patrones más específicos.

Conclusión

El pipeline desarrollado demuestra que la identificación de idioma es resoluble con alta precisión utilizando técnicas clásicas de ML supervisado y características estadísticas de nivel de carácter.

La elección de **n-gramas de caracteres con TF-IDF** es la decisión de ingeniería de características más relevante del proyecto que permite capturar patrones morfológicos exclusivos de cada idioma sin tokenización, stemming ni recursos lingüísticos externos.

La **regresión Logística** emerge como modelo óptimo por su combinación de eficiencia computacional, interpretabilidad y rendimiento en espacios de alta dimensión. Los modelos de boosting obtienen un accuracy 1.7 puntos inferior, confirmando que en este problema el hiperplano de separación lineal es suficiente.

Como trabajo futuro, sería interesante explorar idiomas adicionales (arabe, chino, japonés) y evaluar el rendimiento en textos muy cortos (tweets, hashtags) donde la cantidad de n-gramas disponibles es limitada.

Mejor modelo	Test Accuracy	Macro F1	Errores en test
Logistic Regression (C=10)	97.48%	0.9750	3 / 119 (2.52%)